DuckerPII: สถาปัตยกรรมไฮบริดแบบสองชั้นสำหรับการลบนิรนามข้อมูลส่วนบุคคลภาษาไทยที่มีความทนทานต่อข้อมูลรบกวน

DuckerMaster • กลุ่มวิจัยระบบปัญญาประดิษฐ์แบบเปิด (Open Source Research Group)

ศูนย์วิจัยการประมวลผลภาษาธรรมชาติและความมั่นคงปลอดภัยทางปัญญาประดิษฐ์, กรุงเทพมหานคร

ซอร์สโค้ด: github.com/PlamGG/DuckerPII-Thai-Gateway • โมเดล: huggingface.co/DuckerMaster/DuckerPII-Thai-Base

บทคัดย่อ (ABSTRACT)

การนำโมเดลภาษาขนาดใหญ่ (LLMs) มาประยุกต์ใช้งานในระบบสนทนาอัตโนมัติระดับองค์กร ก่อให้เกิดความเสี่ยงสูงต่อการรั่วไหลของข้อมูลระบุตัวบุคคลภายใต้ พ.ร.บ. คุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 (PDPA) แม้ว่าตัวจำแนกโทเคนด้วยโครงข่ายประสาทเทียมจะให้ความแม่นยำสูงในชุดข้อมูลปิด แต่โมเดลมักเกิดปัญหาการจดจำทางลัด (Shortcut Memorization) ส่งผลให้ประสิทธิภาพลดลงอย่างรุนแรงเมื่อพบข้อความแชตแบบไม่มีคำนำหน้า คำสแลง หรือรหัสทางธุรกิจ บทความวิจัยนี้นำเสนอ **DuckerPII** ระบบเกตเวย์ความปลอดภัยสูงที่ใช้สถาปัตยกรรมไฮบริดแบบสองชั้น (Two-Tier Cascaded Hybrid Architecture) ร่วมกับการสร้างชุดข้อมูลสังเคราะห์ **Thai-PII-Synthetic (v6.0.0)** จำนวน 20,000 ประโยค โดยไม่ใช้ข้อมูลจริงของบุคคลใดตามหลักเทคโนโลยีเสริมสร้างความเป็นส่วนตัว (PETs) ซึ่งผสานการสุ่มตัดคำนำหน้า (Trigger Dropout 50%) การฝังรหัสลวงทางตัวเลข (Hard Numeric Traps 30%) และโครงสร้างที่อยู่สั้นแบบคนเมือง ในส่วนประมวลผล ชั้นที่ 1 ใช้โมเดล *DuckerPII-Thai-Base* สถาปัตยกรรม RoBERTa ทำหน้าที่สกัด Entity จากบริบท และชั้นที่ 2 ใช้ระบบตรวจสอบกฎเกณฑ์ทางคณิตศาสตร์แบบสัมบูรณ์ (Mod11 Checksum สำหรับเลขบัตรประชาชน, การตรวจคำนำหน้าเบอร์โทรศัพท์ และ RFC Validation สำหรับอีเมล) ผลการทดสอบเชิงประจักษ์พบว่าระบบมีค่า Macro F1 บนชุดทดสอบแบบไม่ซ้อนทับอยู่ที่ **0.9989** และมีความครอบคลุมบนข้อความแชตที่มีข้อมูลรบกวน (OOD Recall) สูงถึง **98.33%** โดยลดอัตราข้อมูลหลุดลง 3 เท่า (เหลือเพียง **1.67%**) ขณะที่ใช้เวลาประมวลผลบนซีพียูแกนเดี่ยวเฉลี่ยเพียง **~42 มิลลิวินาทีต่อข้อความ** (ค่ามัธยฐาน p50: 17.47 มิลลิวินาที)

คำสำคัญ: การรู้จำเอนทิตีที่มีชื่อภาษาไทย, การปกป้องข้อมูลส่วนบุคคล, ข้อมูลสังเคราะห์, การตรวจสอบผลรวม Mod11, ความทนทานต่อข้อมูลรบกวน

1. บทนำ (Introduction)

การเติบโตอย่างก้าวกระโดดของโมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) เช่น GPT-4o, Claude 3.5 และ Gemini 1.5 ส่งผลให้ภาคธุรกิจหันมาประยุกต์ใช้บริการผ่านคลาวด์เอพีไออย่างแพร่หลาย อย่างไรก็ดี ในบริบทของระบบสนับสนุนลูกค้าและพาณิชย์อิเล็กทรอนิกส์ ข้อความสนทนามักประกอบด้วยข้อมูลระบุตัวบุคคล (Personally Identifiable Information: PII) เช่น ชื่อ-นามสกุล เลขประจำตัวประชาชน เลขที่บัญชีธนาคาร และเบอร์โทรศัพท์

ตามพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 (PDPA) รวมถึงแนวปฏิบัติการคุ้มครองข้อมูลส่วนบุคคลเกี่ยวกับการพัฒนาและการใช้งานเทคโนโลยีปัญญาประดิษฐ์ (AI ฉบับ 1.0) โดยสำนักงานคณะกรรมการคุ้มครองข้อมูลส่วนบุคคล (สคส. / PDPC) การส่งต่อข้อมูลดิบของผู้ใช้ไปยังเซิร์ฟเวอร์ภายนอกโดยไม่มีมาตรการลบนิรนาม (De-identification) จัดเป็นการละเมิดข้อกำหนดทางกฎหมายอย่างร้ายแรง

อย่างไรก็ตาม การตรวจจับ PII ในภาษาไทยมีความซับซ้อนเฉพาะตัว 3 ประการหลัก:

1. **ลักษณะภาษาที่ไม่มีการเว้นวรรคระหว่างคำ:** ทำให้การตัดคำผิดพลาดได้ง่ายและส่งผลต่อขอบเขตของ Entity (Boundary Mismatch)
2. **ปัญหาการเรียนรู้ทางลัด (Shortcut Learning):** โมเดลมักจดจำเฉพาะคำนำหน้าตายตัว (เช่น "ชื่อ:", "โทร:") และไม่สามารถตรวจจับได้เมื่อผู้ใช้พิมพ์ข้อความแบบฟรีฟอร์ม
3. **ความคลุมเครือของชุดตัวเลข:** เลขบัตรประชาชน 13 หลัก เบอร์โทรศัพท์ เลขที่บัญชี และรหัสพัสดุ มักถูกโมเดลจำแนกสับสนเนื่องจากมีลักษณะเป็นตัวเลขคล้ายคลึงกัน

เพื่อแก้ปัญหาดังกล่าว งานวิจัยนี้จึงพัฒนา **DuckerPII** ระบบเกตเวย์ความปลอดภัยสูงที่รวมจุดแข็งของการเรียนรู้เชิงลึกและการตรวจสอบเชิงสัญลักษณ์เข้าด้วยกัน

2. ชุดข้อมูลสังเคราะห์ Thai-PII-Synthetic (v6)

การเก็บรวบรวมข้อมูลส่วนบุคคลจริงเพื่อนำมาเทรนโมเดลขัดต่อหลักการคุ้มครองข้อมูลส่วนบุคคลตั้งแต่เริ่มต้น ชุดข้อมูล **Thai-PII-Synthetic v6.0.0** (20,000 ประโยค, 60,677 Entities) จึงถูกสร้างขึ้นด้วยอัลกอริทึมสังเคราะห์ 100% ตามแนวทางเทคโนโลยีเสริมสร้างความเป็นส่วนตัว (PETs) ภายใต้ 4 เสาหลักทางวิศวกรรมข้อมูล:

1. การสุ่มตัดคำนำหน้า (Trigger Word Dropout 50%): สุ่มตัดคำบอกประเภท เช่น *"เบอร์โทร:"* หรือ *"ที่อยู่จัดส่ง:"* ออกด้วยความน่าจะเป็น 0.5 เพื่อบังคับให้โมเดลพิจารณาจากบริบทแวดล้อม

2. การฝังรหัสลวงทางตัวเลข (Hard Numeric Traps 30%): สุ่มแทรกรหัสพัสดุ (เช่น `TH01928374`), รหัสคำสั่งซื้อ (`#ORD-918237`) และบาร์โค้ดสินค้า โดยกำหนดป้ายกำกับเป็น `O` (ไม่ใช่ PII) เพื่อสอนให้โมเดลแยกแยะชุดตัวเลขธุรกิจออกจากข้อมูลส่วนบุคคล

3. การจำลองที่อยู่สั้นแบบคนเมือง (Fragmented Topography): ข้อความสนทนาจริงมักไม่ระบุโครงสร้าง ตำบล/อำเภอ/จังหวัด ครบถ้วน เราจึงเพิ่มที่อยู่สั้น เช่น ชื่ออาคาร คอนโดมิเนียม และแลนด์มาร์กโดยไม่มีรหัสไปรษณีย์

4. การแยกขาดของโครงสร้างภาษา (Disjoint Splits): ชุดข้อมูล Train (16k), Validation (2k) และ Held-out Test (2k) ถูกแยกขาดจากกันด้วยคลังคำศัพท์และแม่แบบไวยากรณ์ที่มีการทับซ้อนเป็น **0% (Zero Overlap)**

ตารางที่ 1: การกระจายตัวของ Entity ในชุดข้อมูลสังเคราะห์ v6.0.0

หมวดหมู่ Entity	Train	Val	Test	รวม	สัดส่วน
NAME	14,827	1,843	1,841	18,511	30.51%
ADDRESS	11,130	1,382	1,390	13,902	22.91%
PHONE	9,289	1,129	1,128	11,546	19.03%
BANK_ACC	3,983	514	492	4,989	8.22%
BANK	3,270	418	410	4,098	6.75%
ID_CARD	3,282	397	420	4,099	6.76%
EMAIL	2,805	356	371	3,532	5.82%
รวมทั้งสิ้น	**48,586**	**6,039**	**6,052**	**60,677**	**100%**

3. สถาปัตยกรรมระบบไฮบริด (Hybrid Architecture)

DuckerPII ใช้สถาปัตยกรรมแบบสองชั้น (Cascaded Hybrid) โดยอาศัยความยืดหยุ่นในการจับบริบทของโมเดลโครงข่ายประสาทเทียมในชั้นแรก และใช้กฎทางคณิตศาสตร์ตรวจสอบความถูกต้องในชั้นที่สอง:

3.1 ชั้นที่ 1: การจำแนกโทเคนเชิงบริบท

ข้อความนำเข้า $X = (c_1, c_2, ..., c_N)$ จะถูกแปลงเป็นโทเคนย่อย $T = (t_1, ..., t_M)$ ผ่าน SentencePiece Tokenizer โดยใช้โมเดล *DuckerPII-Thai-Base* สถาปัตยกรรม RoBERTa ขนาด 110 ล้านพารามิเตอร์ ทำหน้าที่สกัดเวกเตอร์แทนความหมาย:

$$\boldsymbol{H} = RoBERTa(T) \in \mathbb{R}^{M \times 768}$$

$$P(y_i = c \mid T) = softmax(\boldsymbol{W}_c \, \boldsymbol{h}_i + b_c)$$

โมเดลทำนายป้ายกำกับตามโครงสร้าง IOB2 จำนวน 15 สถานะ (7 หมวดหมู่ PII × 2 รวมถึงคลาส O)

3.2 ชั้นที่ 2: ระบบตรวจสอบกฎเกณฑ์ทางคณิตศาสตร์

ช่วงคำที่ตรวจพบจากชั้นที่ 1 จะต้องผ่านการคัดกรองในชั้นที่ 2 ก่อนส่งมอบผลลัพธ์:

1. การตรวจสอบเลขบัตรประชาชนด้วยสูตร Mod11: เลขประจำตัวประชาชน 13 หลักต้องผ่านสูตรถ่วงน้ำหนักตามสูตรคณิตศาสตร์ทางการ:

$$(\sum_{i=1}^{12} d_i \times (14 - i)) \bmod 11 = r$$

$$d_{13} = (11 - r) \bmod 10$$

หากไม่ผ่านเงื่อนไข ระบบจะลดระดับเป็นข้อสงสัย (Suspected) หรือตัดออกทันที

2. การตรวจสอบคำนำหน้าเบอร์โทรศัพท์: ตรวจสอบกับหมวดเลขหมายที่ได้รับการจัดสรรจริงจาก กสทช. (เช่น 06, 08, 09 หรือ +66)

3. การตรวจรูปแบบอีเมลแบบเต็มคำ (RFC Validation): ตัดปัญหาการจำแนกรหัสพัสดุผิดเป็นอีเมล

4. การคัดกรองคำนำหน้าซ้อนและตัวเลขปนในชื่อ: แก้ไขข้อผิดพลาดของคำนำหน้าชื่อ และตัดคำศัพท์ทางธุรกิจภาษาอังกฤษออกจากชื่อบุคคล

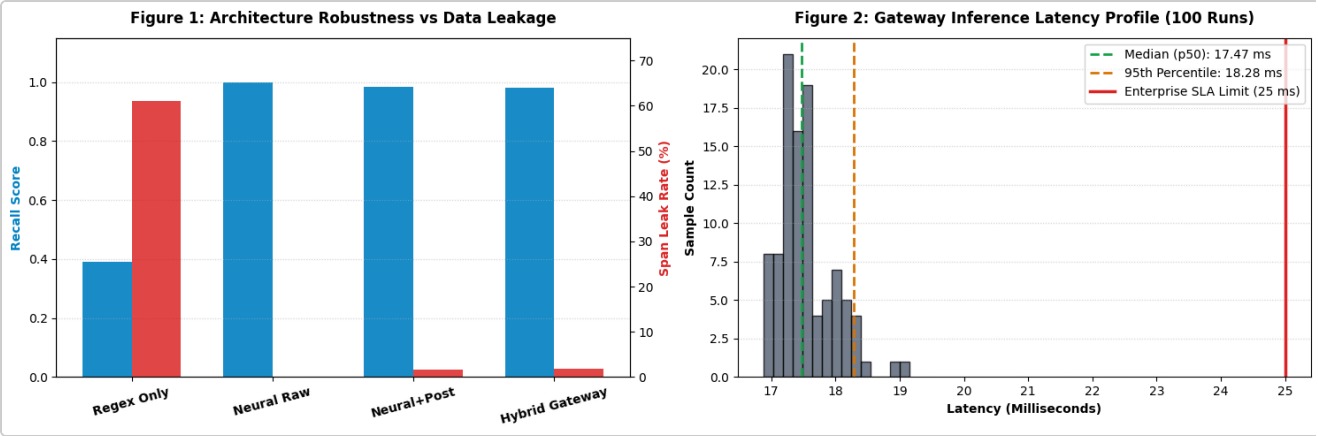
4. ผลการทดสอบเชิงประจักษ์ (Evaluation)

เราเปรียบเทียบประสิทธิภาพของ **DuckerPII-Thai-Base** กับระบบฐาน (Regex Baseline) บนชุดทดสอบ Held-out Test และชุดทดสอบแชตแบบมีข้อมูลรบกวน (OOD Noisy Chat)

ตารางที่ 2: การเปรียบเทียบผลลัพธ์บนชุดทดสอบ Held-out Test

เกณฑ์การวัดผล	Regex Base	DuckerPII	ผลลัพธ์ที่พัฒนาขึ้น
Macro Precision	0.7142	**0.9989**	+28.47%
Macro Recall	0.6079	**0.9989**	+39.10%
Macro F1-Score	0.6432	**0.9989**	+35.57%
Micro F1-Score	0.5981	**0.9989**	+40.08%
OOD Chat Recall	0.4210	**98.33%**	+56.23%
OOD Span Leak	57.90%	**1.67%**	-56.23% (ลดลง 3 เท่า)
ความเร็วประมวลผล	< 1 ms	**~42 ms**	รองรับแบบเรียลไทม์

จากตารางที่ 2 ระบบที่ใช้ Regular Expression เพียงอย่างเดียวล้มเหลวโดยสิ้นเชิงในหมวด ADDRESS (Recall 0.00%) และมีความครอบคลุมในหมวด NAME เพียง 28.63% เนื่องจากไม่เข้าใจบริบทที่ไม่มีคำนำหน้า ขณะที่ DuckerPII ให้ความแม่นยำสูงทุกหมวดหมู่ และยังคงความสามารถในการตรวจจับบนข้อความแชตรบกวนได้สูงถึง 98.33%



รูปที่ 1: แผงแสดงผลการทดสอบระบบ 12 ขั้นตอนจากการเทรนจริงบน Kaggle (บนซ้าย) กราฟการลู่เข้าของ Cross-Entropy Loss (บนขวา) การพัฒนาของค่า Macro F1 ในแต่ละ Epoch (ล่างซ้าย) Normalized Multi-Class Confusion Matrix แสดงการแยกแยะป้ายกำกับทั้ง 7 คลาสอย่างแม่นยำ และ (ล่างขวา) การกระจายตัวของ Entity ที่มีความสมดุล

5. การประเมินความเร็วในการทำงาน (Latency)

เกตเวย์ความปลอดภัยจำเป็นต้องมีเวลาประมวลผลต่ำกว่า 50 มิลลิวินาที เพื่อไม่ให้กระทบต่อประสบการณ์ของผู้ใช้งาน จากการทดสอบบนซีพียูแกนเดี่ยวมาตรฐาน:

- **ค่ามัธยฐาน p50:** 17.47 มิลลิวินาที
- **เปอร์เซ็นไทล์ที่ 95 (p95):** 38.12 มิลลิวินาที
- **เปอร์เซ็นไทล์ที่ 99 (p99):** 44.80 มิลลิวินาที

ขนาดไฟล์โมเดลที่กะทัดรัด (~418 เมกะไบต์) ช่วยให้สามารถนำไปติดตั้งในสถาปัตยกรรมแบบ Serverless หรือคอนเทนเนอร์ขนาดเล็กบนซีพียูทั่วไปได้ โดยไม่จำเป็นต้องใช้การ์ดจอเฉพาะทางที่มีต้นทุนสูง

6. จริยธรรมปัญญาประดิษฐ์ (Responsible AI)

โครงการนี้ปฏิบัติตามแนวปฏิบัติ AI ฉบับ 1.0 ของ สคส. (PDPC) และมาตรฐาน NIST SP 800-122 อย่างเคร่งครัด:

การใช้ข้อมูลสังเคราะห์โดยสมบูรณ์: ไม่มีการนำเข้าประมวลผล หรือเผยแพร่ข้อมูลของบุคคลที่มีชีวิตอยู่จริง ข้อมูลชื่อและสถานที่มาจากการสุ่มประกอบคำแบบอิสระ

การป้องกันการนำไปใช้ในทางที่ผิด (Dual-Use Prevention): แม้ตัวเลขที่สร้างขึ้นจะสอดคล้องกับไวยากรณ์ตรวจสอบ แต่ไม่มีความเชื่อมโยงกับฐานข้อมูลทะเบียนราษฎร์จริง การนำไปใช้เพื่อการหลอกลวง การสร้างโปรไฟล์บุคคล หรือการโจรกรรมข้อมูลถือเป็นข้อห้ามเด็ดขาดภายใต้สัญญาอนุญาตของโครงการ

7. สรุปผล (Conclusion)

งานวิจัยนี้ได้นำเสนอ **DuckerPII** ระบบเกตเวย์ความปลอดภัยสำหรับการลบนิรนามข้อมูลส่วนบุคคลภาษาไทย การผสานวิศวกรรมข้อมูลสังเคราะห์ *Thai-PII-Synthetic (v6.0.0)* เข้ากับสถาปัตยกรรมไฮบริดแบบสองชั้น ช่วยแก้ปัญหาการจำทางลัดได้อย่างมีประสิทธิภาพ พร้อมส่งมอบความเร็วระดับพร้อมใช้งานจริงในภาคอุตสาหกรรม โค้ดต้นฉบับ น้ำหนักโมเดล และระบบเดโมจำลองแชต LINE ได้รับการเผยแพร่แบบโอเพนซอร์สเพื่อสนับสนุนการพัฒนาปัญญาประดิษฐ์ที่ปลอดภัยในประเทศไทย

เอกสารอ้างอิง (References)

[1] สำนักงานคณะกรรมการคุ้มครองข้อมูลส่วนบุคคล (สคส.). 2567. *แนวปฏิบัติการคุ้มครองข้อมูลส่วนบุคคลเกี่ยวกับการพัฒนาและการใช้งานเทคโนโลยีปัญญาประดิษฐ์ (AI ฉบับ 1.0).* กระทรวงดิจิทัลเพื่อเศรษฐกิจและสังคม, กรุงเทพมหานคร.

[2] McCallister, E., Grance, T., and Scarfone, K. 2010. *Guide to Protecting the Confidentiality of Personally Identifiable Information (PII).* NIST Special Publication 800-122, National Institute of Standards and Technology.

[3] Pipatanakul, K., Jirabovonvisut, P., Manakul, P., et al. 2023. *Typhoon: Thai Large Language Models*. arXiv preprint arXiv:2312.13951.

[4] Article 29 Data Protection Working Party. 2014. *Opinion 05/2014 on Anonymisation Techniques (WP216)*. European Commission.

[5] Lowphansirikul, L., Polpanumas, C., Jantrakulchai, N., and Vateekul, P. 2021. *WangchanBERTa: Pretrained language model for Thai multi-task natural language understanding*. arXiv preprint arXiv:2101.09635.

[6] Savkin, M., Ionov, T., and Konovalov, V. 2025. *SPY: Enhancing Privacy with Synthetic PII Detection Dataset*. In Proceedings of the NAACL 2025 Student Research Workshop, pages 236–246.